

Avaliação Comparativa de Representações Textuais Aplicadas à Triagem Automática de Currículos

TF-IDF, Sentence-Transformers e Embeddings de LLMs

Autor: Brenno Murakami | **Orientador:** Prof. Vilson Francisco Maziero

IFSP — Campus Presidente Epitácio | Bacharelado em Ciência da Computação | 2026

O Problema da Triagem de Currículos

Desafio do Volume

Processos seletivos modernos enfrentam um **grande volume de candidaturas**, tornando a análise manual difícil de escalar e custosa.

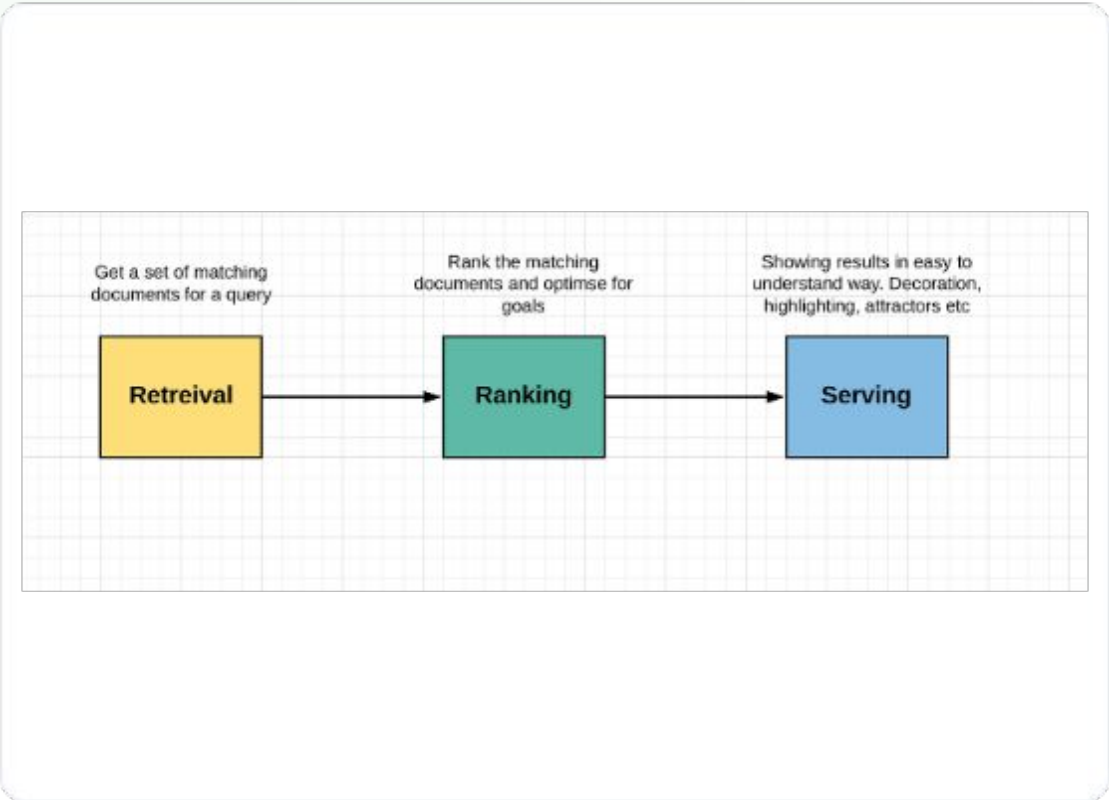
A triagem inicial é crítica: separar perfis aderentes de inadequados de forma rápida e justa.

Heterogeneidade Textual

Currículos são documentos **pouco estruturados** e com vocabulário variado.

Vagas e candidatos usam termos diferentes para competências similares (ex: "Interfaces Web" vs "Frontend").

Triagem como Recuperação de Informação



- **Vaga como Consulta:** A descrição atua como a necessidade de informação.
- **Currículos como Documentos:** A coleção de dados a ser explorada.
- **Ordenação:** O sistema recupera e ranqueia documentos pela aderência.

Questão Central do Trabalho

"Qual representação textual oferece o melhor equilíbrio entre desempenho, custo computacional e interpretabilidade?"

01 Desempenho

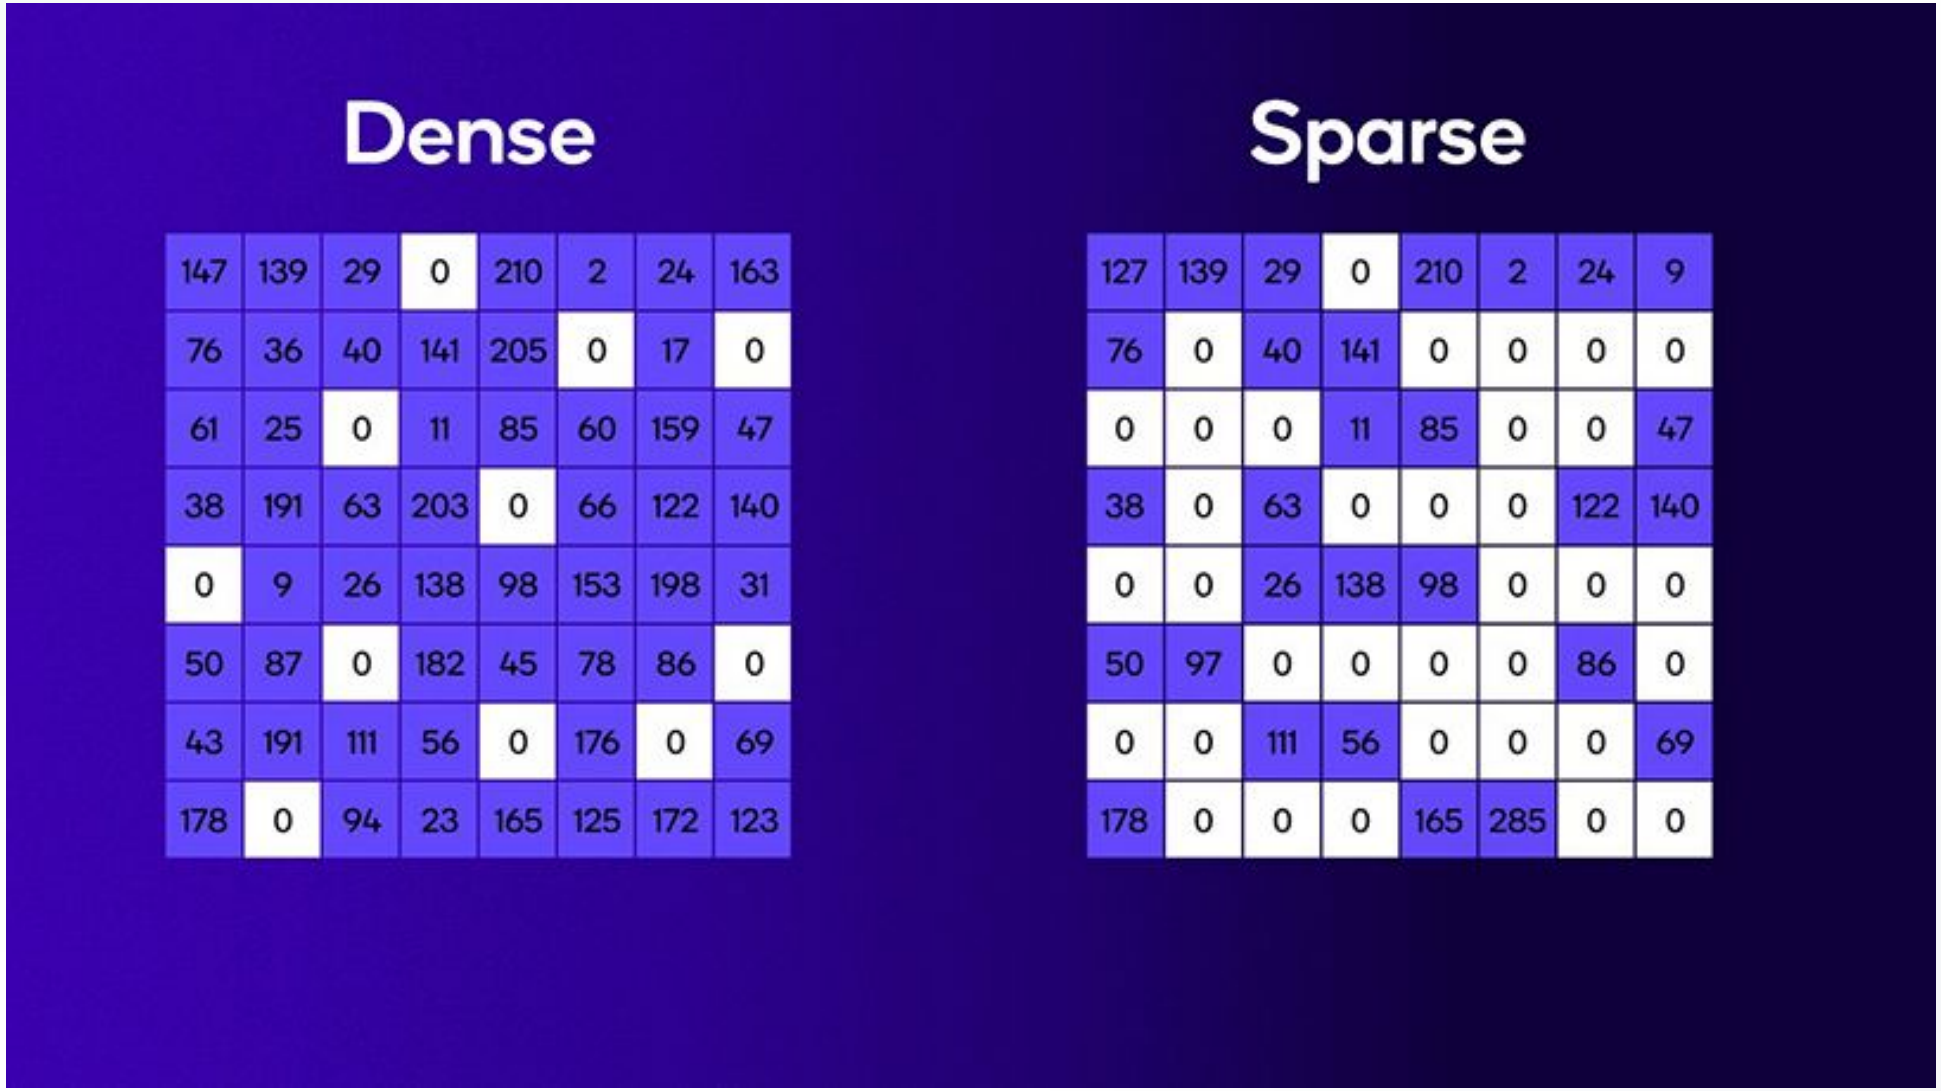
02 Custo Computacional

03 Interpretabilidade

Pipeline Experimental



Representação Esparsa vs Densa



Representações Textuais

Transformando texto em vetores

Pipeline técnico

Da representação textual em vetores à classificação e avaliação

1. Texto



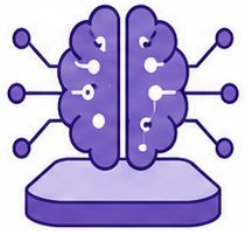
- Spring
- REST
- SQL
- Git
- Java

2. Representação Vetorial (TF-IDF)

Termo	Peso (TF-IDF)
Spring	0,91
REST	0,86
SQL	0,82
Git	0,74
Java	0,69

[0,91, 0,86, 0,82, 0,74, 0,69]

3. Algoritmo de Classificação



- Regressão Logística
- SVM
- XGBoost

4. Saída



Classe: Adequado

Probabilidade:

0,87

5. Avaliação



Classificação
- Precisão
- Revocação
- F1-Score



Ranqueamento
- Precision@k
- MAP
- NDCG



Operacionais
- Tempo de Vetorização
- Latência de Inferência
- Interpretabilidade

TF-IDF: Representação Lexical

Baseado em Palavras

Representação Esparsa: Vetores longos onde a maioria dos valores é zero.

Peso Estatístico: Valoriza termos frequentes no documento mas raros na coleção.

Interpretabilidade: Conexão direta entre o valor no vetor e a palavra original.

TF-IDF: Representação Lexical

Currículo:

Over 3 years of experience serving as a key contributor across all software development life cycle phases, including analysis, architectural design, prototyping, development, and testing of applications using **Java/J2EE** technologies in various domains.

Excellent working experience in **backend development** using different **Spring** modules like Spring Core Container Module, AOP, MVC, Security, Data, Transaction Management etc.

Experienced in developing **Microservices** with Spring Boot, Spring **REST**, Spring Cloud, etc.

Experienced in working with **SQL** databases like MySQL, PostgreSQL, Oracle and have some knowledge of NoSQL databases like MongoDB.

Experienced in working with Version Control Tools like SVN and **Git**.

Palavra / termo	Peso TF-IDF
Spring	0,91
Rest	0,86
SQL	0,82
Microservices	0,78
Git	0,74
Java	0,69

Sentence-Transformers: Significado

Representação Densa

Utiliza a arquitetura **Transformer** para gerar vetores compactos que representam o **significado semântico** da sentença.

Captura o contexto: palavras próximas no espaço vetorial possuem sentidos similares.

Atenção e Contexto

O mecanismo de **Autoatenção** permite que o modelo analise cada palavra considerando todas as outras na frase.

Fundamental para resolver a heterogeneidade de vocabulário em currículos.

Embeddings de LLMs



Modelos de Larga Escala

Extraídos de modelos massivos (ex: GPT, Claude, Llama), capturando nuances contextuais ricas.



Espaço Semântico Robusto

Tendem a generalizar melhor para termos técnicos e domínios específicos de mercado.



Trade-off de Custo

Oferecem maior potencial de precisão, porém com maior custo computacional e latência.

Comparação: Representações Textuais

Característica	TF-IDF	Sentence-Transformers	LLM Embeddings
Tipo de Vetor	Esparso (Lexical)	Denso (Semântico)	Denso (Contextual)
Capacidade Semântica	Baixa	Alta	Muito Alta
Interpretabilidade	Alta (Palavras)	Baixa (Vetor abstrato)	Baixa (Vetor abstrato)
Custo Computacional	Mínimo	Intermediário	Elevado

Algoritmos de Classificação

Pipeline técnico

Da representação textual em vetores à classificação e avaliação

1. Texto



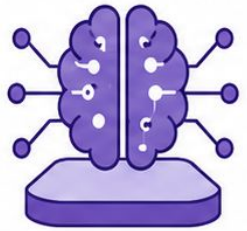
- Spring
- REST
- SQL
- Git
- Java

2. Representação Vetorial (TF-IDF)

Termo	Peso (TF-IDF)
Spring	0,91
REST	0,86
SQL	0,82
Git	0,74
Java	0,69

[0,91, 0,86, 0,82, 0,74, 0,69]

3. Algoritmo de Classificação



- Regressão Logística
- SVM
- XGBoost

4. Saída



Classe: Adequado

Probabilidade:

0,87

5. Avaliação



Classificação
- Precisão
- Revocação
- F1-Score



Ranqueamento
- Precision@k
- MAP
- NDCG



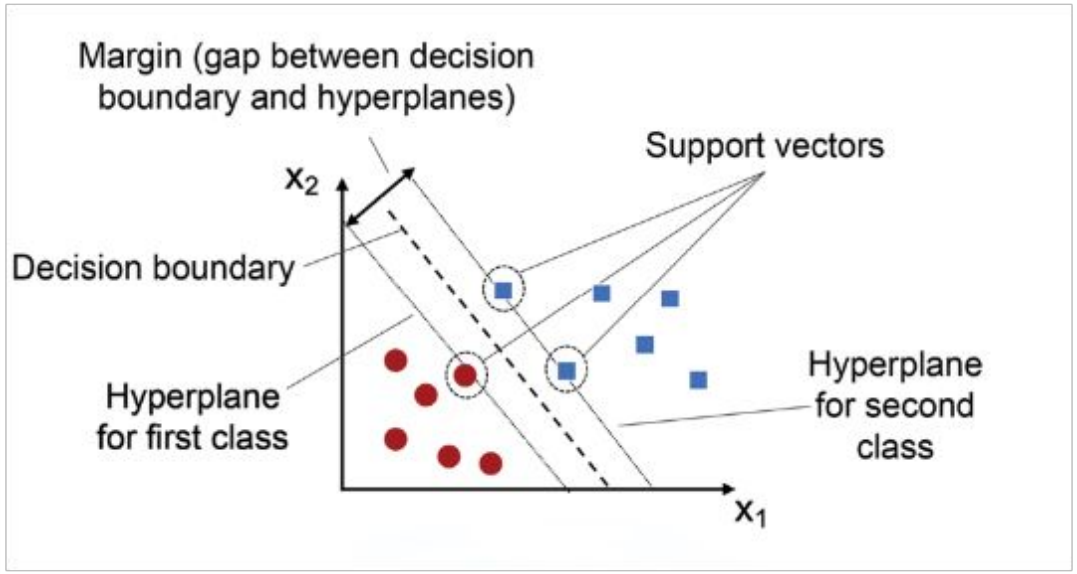
Operacionais
- Tempo de Vetorização
- Latência de Inferência
- Interpretabilidade

Regressão Logística e SVM

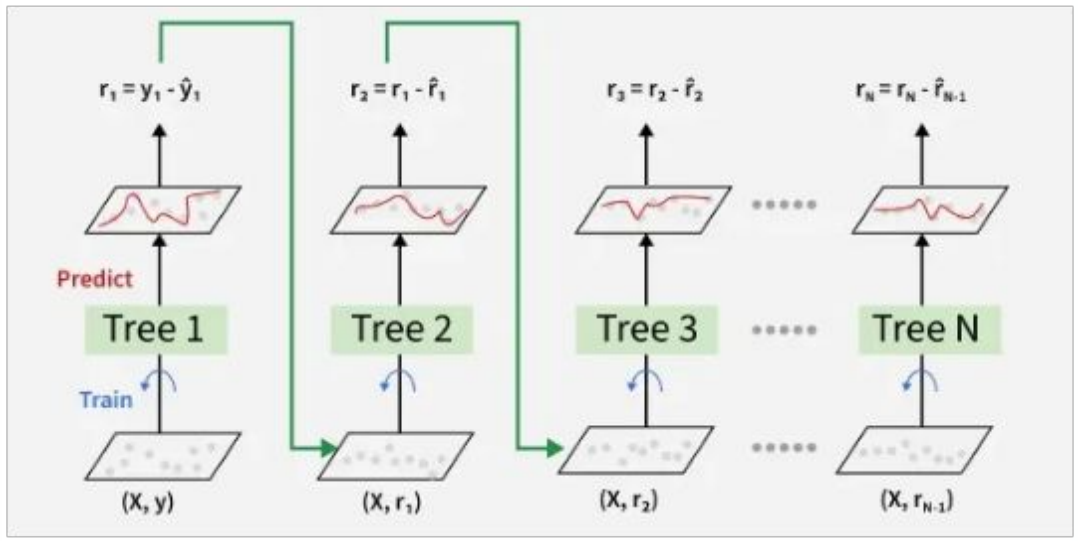
Modelos Lineares

Regressão Logística: Atribui pesos aos atributos e gera uma probabilidade de aderência.

SVM: Busca a fronteira de decisão que maximiza a margem entre classes.



XGBoost: Ensemble de Árvores



Gradient Boosting

Combina múltiplas **árvores de decisão** em sequência.

Cada nova árvore foca em corrigir os erros das anteriores.

Capaz de capturar relações **não-lineares** complexas entre as competências.

Comparação: Classificadores

Modelo	Abordagem	Vantagem Principal	Complexidade
Regressão Logística	Linear (Probabilidade)	Interpretabilidade alta	Baixa
SVM	Max-Margin	Robusto em alta dimensão	Média
XGBoost	Tree Boosting	Captura relações complexas	Alta

Pipeline técnico

Da representação textual em vetores à classificação e avaliação

1. Texto



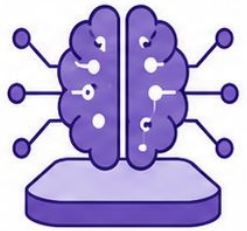
- Spring
- REST
- SQL
- Git
- Java

2. Representação Vetorial (TF-IDF)

Termo	Peso (TF-IDF)
Spring	0,91
REST	0,86
SQL	0,82
Git	0,74
Java	0,69

[0,91, 0,86, 0,82, 0,74, 0,69]

3. Algoritmo de Classificação



- Regressão Logística
- SVM
- XGBoost

4. Saída



Classe: Adequado

Probabilidade:

0,87

5. Avaliação



Classificação
- Precisão
- Revocação
- F1-Score



Ranqueamento
- Precision@k
- MAP
- NDCG



Operacionais
- Tempo de Vetorização
- Latência de Inferência
- Interpretabilidade

Métricas de Avaliação

Classificação

Precisão: Evita falsos positivos.

Revocação: Não perde talentos bons.

F1-Score: Equilíbrio harmônico.

Ranqueamento

Precision@k: Relevância no topo.

MAP: Qualidade média da ordem.

NDCG: Valoriza aderência graduada.

Operacionais

Tempo de Vetorização

Latência de Inferência

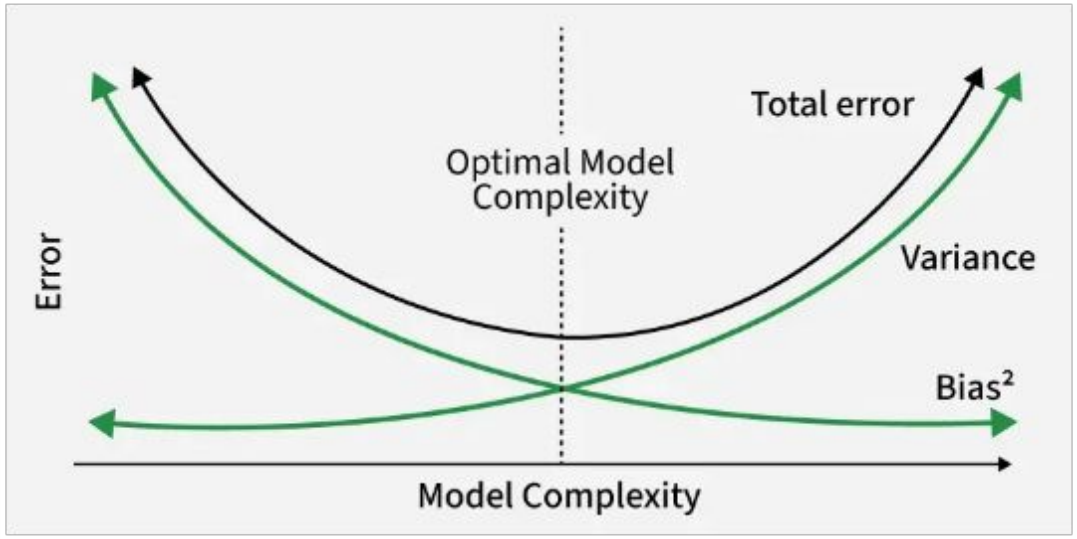
Interpretabilidade

Custo e Interpretabilidade

O Equilíbrio Necessário

Interpretabilidade: Essencial para auditoria e confiança do recrutador (saber POR QUE o sistema indicou aquele currículo).

Custo: Viabilidade financeira e técnica para escalar a triagem.



Dataset e Anotação

Origem dos Dados

Resume Dataset: 2.484 currículos reais em inglês.

Categorias: 24 áreas profissionais (TI, Saúde, RH, etc).

Processo de Anotação

Classes: Adequado, Parcialmente Adequado e Inadequado.

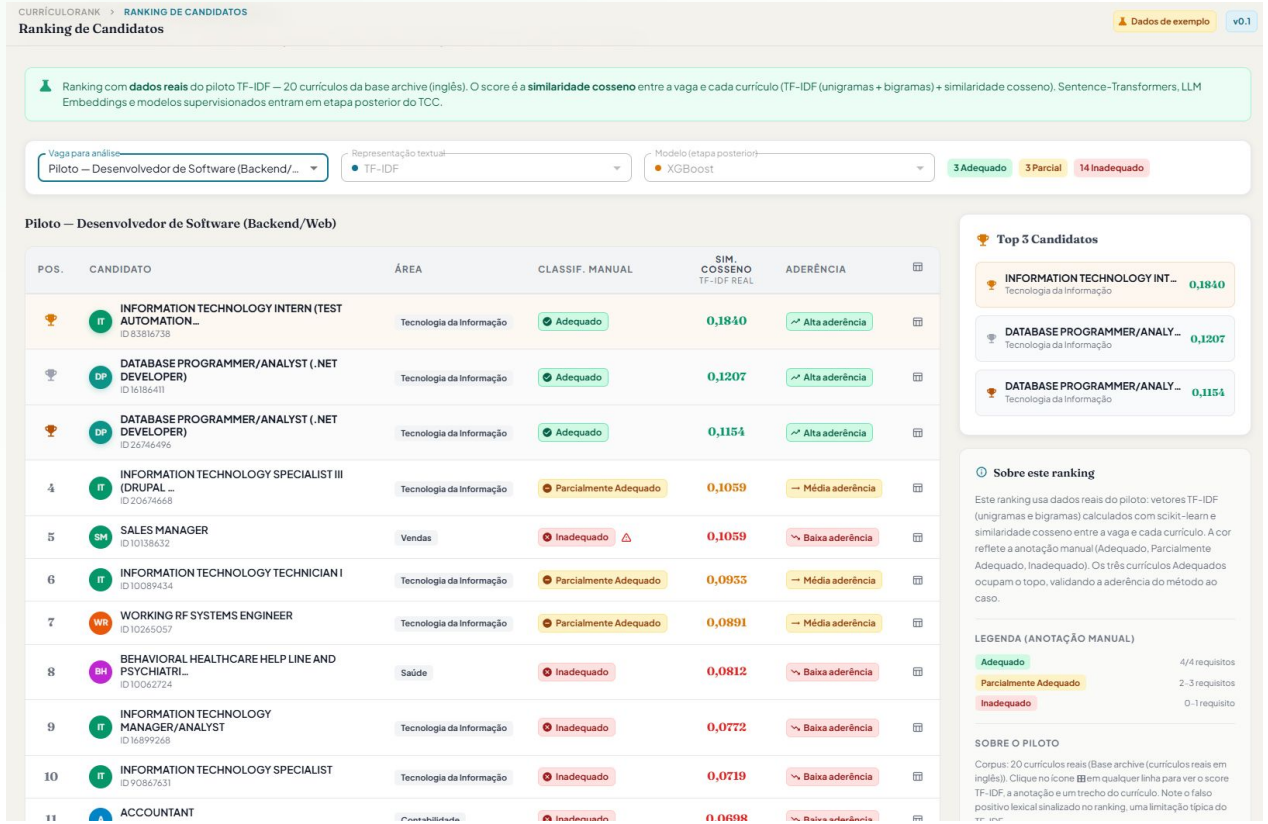
Anotação Manual: Baseada na vaga de referência (Software Developer).

Resultados do Experimento Piloto

Ranking Preliminar com TF-IDF + Similaridade do Cosseno

Currículo ID	Anotação Manual	Similaridade	Posição
83816738	**Adequado**	0,1840	1º
16186411	**Adequado**	0,1207	2º
26746496	**Adequado**	0,1154	3º
20674668	Parcial. Adequado	0,1059	4º

Aplicação CurrículoRank



Visualização do Pipeline

Protótipo para demonstração visual dos rankings.

Exibe níveis de aderência e métricas comparativas.

Camada de Visualização: Demonstra como o recrutador interage com os resultados dos modelos.

Conclusões Parciais e Evolução

TCC 1

Fundamentação,
Pipeline e Piloto TF-IDF.

Implementação

Sentence-Transformers
e Embeddings LLM.

Supervisionado

Treinamento de
LR, SVM e XGBoost.

Finalização

Análise Comparativa
Completa e Defesa.

Pipeline técnico

Da representação textual em vetores à classificação e avaliação

1. Texto



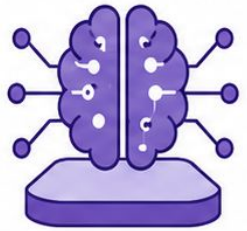
- Spring
- REST
- SQL
- Git
- Java

2. Representação Vetorial (TF-IDF)

Termo	Peso (TF-IDF)
Spring	0,91
REST	0,86
SQL	0,82
Git	0,74
Java	0,69

[0,91, 0,86, 0,82, 0,74, 0,69]

3. Algoritmo de Classificação



- Regressão Logística
- SVM
- XGBoost

4. Saída



Classe: Adequado

Probabilidade:

0,87

5. Avaliação



Classificação
- Precisão
- Revocação
- F1-Score



Ranqueamento
- Precision@k
- MAP
- NDCG



Operacionais
- Tempo de Vetorização
- Latência de Inferência
- Interpretabilidade

Obrigado!

Perguntas e Considerações

Brenno Murakami

brenno.murakami@ifsp.edu.br

IFSP — Presidente Epitácio